

**PAMUKKALE ÜNİVERSİTESİ**  
**MÜHENDİSLİK FAKÜLTESİ,**  
**ENDÜSTRİ MÜHENDİSLİĞİ BÖLÜMÜ**



**IENG435**  
**PROBLEM ÇÖZMEDE**  
**SEZGİSEL YÖNTEMLER**

**DÖNEM PROJESİ**

Hazırlayan: Dilara ŞAHBAZ

Öğretim Üyesi: Prof. Dr. Can Berk Kalaycı

Bahar, 2024-2025

**Pamukkale Üniversitesi Mühendislik Fakültesi, Endüstri Mühendisliği Bölümü**  
**Denizli**

## İçindekiler

|                                                                            |   |
|----------------------------------------------------------------------------|---|
| 1.Yöntem.....                                                              | 3 |
| 2.Pilot Çalışma .....                                                      | 3 |
| 2.1Parametrelerin Belirlenmesi.....                                        | 4 |
| 3.Ana Deney .....                                                          | 4 |
| 3.1 Parametrelerin Belirlenmesi .....                                      | 4 |
| 3.Ana Deneyin Parametrelerinin Diğer Veri Setleri Üzerinde Denenmesi ..... | 7 |
| 3.1 Bays.29 Veri Setinin Optimum Çözümü.....                               | 7 |
| 3.2 Att48 Veri Setinin Optimum Çözümü.....                                 | 8 |
| 4.Sonuç.....                                                               | 8 |

# Gezgin Satıcı Problemi İçin Sezgisel Algoritmayla Parametre Optimizasyonu ve Deneysel Tasarım

## 1.Yöntem

Kullanılan çalışmalarda yöntem olarak faktöriyel deneysel tasarım kullanılmıştır. **Faktöriyel deney tasarımı**, birden fazla parametrenin aynı anda incelendiği sistematik bir yöntemdir. Her parametrenin farklı değerleri denir ve tüm kombinasyonlar test edilerek hem tekil etkiler hem de parametreler arası etkileşimler analiz edilir. Bu sayede, en uygun parametre kombinasyonları daha etkili şekilde belirlenebilir.

## 2.Pilot Çalışma

- Bu tabloda yer alan sayılar, pilot çalışma kapsamında kullanılan tam faktöriyel deneysel tasarımın bir çıktısıdır. Her bir satır, farklı bir parametre kombinasyonunun sonucunu göstermektedir.
- Hangi popülasyon büyüklüğü ve iterasyon sayısı kombinasyonunun en iyi sonuçları verdiğini belirlemek ve aynı zamanda işlem süresi (zaman karmaşıklığı) ile çözüm kalitesi arasındaki dengeyi analiz etmek amacıyla yapılmıştır.
- Ana deney çalışmasında popülasyon ve iterasyon sayısını sabitlemek amacıyla yapılan ön çalışmadır.

Tablo 1

| Pop Size | Iterations | Best Fitness | Duration (s) |
|----------|------------|--------------|--------------|
| 10       | 10000      | 27350.9243   | 0.000389338  |
| 10       | 50000      | 26675.0412   | 0.00019002   |
| 10       | 100000     | 26427.2761   | 0.000178099  |
| 20       | 10000      | 27297.5611   | 0.000345469  |
| 20       | 50000      | 26857.2807   | 0.000354052  |
| 20       | 100000     | 27436.8897   | 0.000345945  |
| 30       | 10000      | 26835.3217   | 0.000527859  |
| 30       | 50000      | 25625.6358   | 0.000514746  |
| 30       | 100000     | 26260.1952   | 0.000522137  |

## 2.1 Parametrelerin Belirlenmesi

**Popülasyon sayısı:** Popülasyondaki birey sayısının gereğinden fazla olması çözüm süresini uzatırken, birey sayısının az olması popülasyonun istenen çözüm değerine ulaşamamasına sebep olabilir.

**İterasyon sayısı:** Genetik algorithmada iterasyon sayısı, algoritmanın kaç nesil boyunca evrimleşeceğini belirler. Bu parametre, algoritmanın başarısı ve verimliliği üzerinde doğrudan etkili olan kritik bir unsurdur. İterasyon sayısının fazla olması optimum çözüme ulaşılmasını yakınsar (garanti etmez) fakat bu durum fazla işlem süresi gerektirir ve Genetik algoritma gereği yerel optimumlarda sıkışabilir.

### Parametreler:

| Parametre    | Açıklama                                        | Deneyisel Değerler            |
|--------------|-------------------------------------------------|-------------------------------|
| Pop Size     | Genetik algorithmadaki popülasyon büyüklüğü     | 10, 20, 30                    |
| Iterations   | Algoritmanın çalıştığı iterasyon (nesil) sayısı | 10.000, 50.000, 100.000       |
| Best Fitness | En iyi bulunan çözüm rotasının toplam mesafesi  | (Çözüme bağlı olarak değişir) |
| Duration (s) | Hesaplama süresi (saniye cinsinden)             | (Otomatik ölçülür)            |

## 3. Ana Deney

Bu çalışmada, Berlin52 problemi üzerinde genetik algoritmanın performansını etkileyen parametreleri optimize etmek amacıyla faktöriyel deneyisel tasarım benimsenmiştir. Deneyisel tasarımlar, çeşitli parametre kombinasyonlarının çözüm kalitesi üzerindeki etkilerini değerlendirmek üzere gerçekleştirilmiştir. Pilot çalışmanın ilk 2 en iyi fitness değerlerine göre deneyisel tasarımlar yapılmıştır.

Elitizm oranı 0.1, 0.2, 0.3 parametreleri olarak belirlenmiştir.

Çaprazlama oranı 0.5, 0.7, 0.9 parametreleri olarak belirlenmiştir.

Mutasyon oranı 0.01, 0.05, 0.1 parametreleri olarak belirlenmiştir.

### 3.1 Parametrelerin Belirlenmesi

**Elitizm oranı:** Her nesilde bulunan en iyi bireylerin belirli bir kısmının doğrudan bir sonraki nesle aktarılmasını ifade eder. Bu sayede, yüksek kaliteli çözümlerin rastgelelik içeren genetik operatörler (çaprazlama ve mutasyon) nedeniyle kaybolması engellenir. Elitizm oranı, bu aktarımın ne kadar bireyi kapsayacağını belirler ve genellikle popülasyonun belli bir yüzdesi olarak tanımlanır. Elitizm oranı çok yüksek tutulursa, popülasyonda çeşitlilik azalabilir. Bu durum algoritmanın yeni ve farklı çözümleri keşfetme kapasitesini sınırlar ve algoritmanın yerel optimumlara takılma olasılığını artırır. Bu yüzden elitizm oranının dengeli olması gerekir.

**Çaprazlama oranı:** Genetik algoritmalar (GA), çözüm uzayında daha iyi bireyler elde etmek amacıyla biyolojik evrim süreçlerini taklit eden sezgisel bir optimizasyon yöntemidir. Bu algoritmalarda çaprazlama (crossover), mevcut çözümlerden yeni bireyler üretmek için kullanılan temel operatörlerden biridir. Çaprazlama oranı, popülasyonda kaç bireyin bu işlemle yeniden kombinasyona tabi tutulacağını belirler ve algoritmanın keşif (exploration) yeteneğini doğrudan etkiler.

Yüksek çaprazlama oranı, çözüm uzayında daha geniş bir arama yapılmasını sağlayarak yerel optimumlardan kaçınılmasına katkıda bulunabilir. Ancak bu oran çok yüksek olduğunda, elit bireylerin korunması zorlaşabilir ve algoritmanın yakınsama (convergence) hızı düşebilir. Öte yandan, düşük çaprazlama oranı daha muhafazakâr bir arama sağlar, ancak çeşitliliği azaltarak erken yakınsama riskini artırabilir. Bu nedenle, çaprazlama oranı dikkatli bir şekilde seçilmeli; problem yapısına ve diğer parametrelere bağlı olarak dengeli bir değer belirlenmelidir.

**Mutasyon oranı:** Mutasyon, genetik algoritmalarda bireylerin genetik yapısını rastgele değiştirerek popülasyona çeşitlilik kazandıran temel operatörlerden biridir. Mutasyon oranı, her bireydeki genlerin mutasyona uğrama olasılığını belirler ve algoritmanın hem keşif (exploration) kapasitesini hem de yerel minimumlara takılma riskini azaltmada önemli bir rol oynar.

Düşük mutasyon oranı, algoritmanın mevcut iyi çözümleri koruyarak istikrarlı bir şekilde yakınsamayı sağlar. Ancak, bu durumda çözüm uzayı yeterince araştırılamayabilir ve algoritma yerel optimumlara sıkışabilir. Yüksek mutasyon oranı ise popülasyon çeşitliliğini artırarak daha geniş bir arama yapılmasına olanak tanır, ancak bu durum algoritmanın rastgeleliğini artırarak iyi çözümlerin bozulmasına ve yakınsamanın gecikmesine neden olabilir. Bu nedenle mutasyon oranı, çözüm kalitesi ve algoritmanın etkinliği açısından kritik olup problem türüne uygun şekilde dikkatle belirlenmelidir.

**Tablo 2**

| Dataset    | PS | Iterations | ER  | CR  | MR   | Seed | Best Fitness |
|------------|----|------------|-----|-----|------|------|--------------|
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 0    | 8680.235325  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 1    | 8720.248132  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 2    | 8947.292515  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 3    | 8997.266686  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 4    | 9040.712302  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 5    | 9155.19087   |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 6    | 9179.957901  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 7    | 9193.509652  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 8    | 9206.556261  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 9    | 9207.838877  |

**Tablo 2’ de** pilot çalışma sonucu popülasyon sayısı 30, iterasyon sayısı 1e5 olarak sabitlenmiştir. Çaprazlama oranı, elitizm oranı ve mutasyon oranı problem için dengeli olarak belirlenerek parametrelili oluşturulmuştur. 10 adet seed rastgele şekilde belirlenip kodun içine dahil edilmiştir ve her iterasyonda çalıştırılmıştır. En iyi fitness değeri 8680 çıkmıştır.

**Tablo 3**

| Dataset    | PS | Iterations | ER  | CR  | MR   | Seed | Best Fitness |
|------------|----|------------|-----|-----|------|------|--------------|
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 0    | 9636.761626  |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 1    | 9946.128147  |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 2    | 10206.75217  |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 3    | 10265.24735  |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 4    | 10300.1316   |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 5    | 10341.22756  |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 6    | 10379.7188   |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 7    | 10406.72139  |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 8    | 10447.71086  |
| [[1.000e+0 | 30 | 50000      | 0.1 | 0.5 | 0.01 | 9    | 10543.49357  |

**Tablo 3’ te** pilot çalışma sonucu popülasyon sayısı 30, iterasyon sayısı 5e4 olarak sabitlenmiştir. Çaprazlama oranı, elitizm oranı ve mutasyon oranı problem için dengeli olarak belirlenerek parametrelili oluşturulmuştur. 10 adet seed rastgele şekilde belirlenip kodun içine dahil edilmiştir ve her iterasyonda çalıştırılmıştır. En iyi fitness değeri 9636 çıkmıştır.

#### **Tablo 2 ve Tablo 3’ ün Karşılaştırılması**

Popülasyon sayısı 30, iterasyon sayısı 1e5 olduğunda diğer parametrelerle birlikte daha iyi sonuç vermiştir. Yani iterasyon arttıkça optimum çözüme yaklaşma oranı artmıştır.

**Tablo 4**'te iterasyon sayısı 1e5 şeklinde sabit kalarak popülasyon sayısı 30 yerine 40 yapılarak da denenmiştir ancak optimum çözümden uzaklaşmıştır.

**Tablo 4**

| Dataset    | PS | Iterations | ER  | CR  | MR   | Seed | Best Fitness |
|------------|----|------------|-----|-----|------|------|--------------|
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 0    | 9040.84355   |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 1    | 9072.227874  |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 2    | 9216.29996   |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 3    | 9264.552143  |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 4    | 9270.091201  |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 5    | 9270.882899  |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 6    | 9319.111397  |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 7    | 9341.108801  |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 8    | 9374.116915  |
| [[1.000e+0 | 40 | 100000     | 0.1 | 0.5 | 0.01 | 9    | 9384.094421  |

### 3.Ana Deneyin Parametrelerinin Diğer Veri Setleri Üzerinde Denenmesi

#### 3.1 Bays.29 Veri Setinin Optimum Çözümü

**Tablo 5**

| PS | Iterations | ER  | CR  | MR   | Seed | Best Fitness |
|----|------------|-----|-----|------|------|--------------|
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 0    | 9074.148048  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 1    | 9074.148048  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 2    | 9074.148048  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 3    | 9112.542236  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 4    | 9112.542236  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 5    | 9120.338841  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 6    | 9170.054128  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 7    | 9170.303781  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 8    | 9170.303781  |
| 30 | 100000     | 0.1 | 0.5 | 0.01 | 9    | 9181.744782  |

### 3.2 Att48 Veri Setinin Optimum Çözümü

Tablo 6

| Dataset    | PS | Iterations | ER  | CR  | MR   | Seed | Best Fitness |
|------------|----|------------|-----|-----|------|------|--------------|
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 0    | 36701.84162  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 1    | 36745.97998  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 2    | 37595.82539  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 3    | 37610.21573  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 4    | 38029.64327  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 5    | 38268.71783  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 6    | 38583.22852  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 7    | 39036.02173  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 8    | 39055.80561  |
| [[1.000e+0 | 30 | 100000     | 0.1 | 0.5 | 0.01 | 9    | 39088.01976  |

### 4.Sonuç

Tüm veri setleri için popülasyon sayısının 30, iterasyon sayısının ise 1e5 olarak sabitlenmesi durumunda; elitizm oranı 0.1, çaprazlama oranı 0.5 ve mutasyon oranı 0.01 olarak belirlendiğinde, genellikle en iyi sonuçların elde edildiği gözlemlenmiştir.